Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №1
По дисциплине: «Основы машинного обучения»
Тема: «Знакомство с анализом данных: предварительная обработка и визуализация»

Выполнил:
Студент 2-го курса
Группы АС-68
Козляковская М.В.
Проверил:
Крощенко А.А.

Брест 2026

Цель: Получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Вариант 3
Выборка Iris. Классический набор данных для классификации, содержащий измерения длины и ширины чашелистиков и лепестков для трех видов ирисов.
Задачи:
1. Загрузите данные и проверьте, есть ли в них пропущенные значения.
2. Выведите количество образцов каждого вида ириса.
3. Постройте парные диаграммы рассеяния (pair plot) для всех признаков, чтобы визуально оценить их разделимость.
4. Для каждого вида ириса рассчитайте среднее значение по каждому из четырех признаков.
5. Создайте "ящик с усами" (box plot) для признака Petal Length (cm), чтобы сравнить его распределение по разным видам ирисов.
6. Стандартизируйте данные (приведите к нулевому среднему и единичному стандартному отклонению).

```
import seaborn as sns
import pandas as pd
import matplotlib.pyplot as plt

# Загрузка данных
file = pd.read_csv("iris.csv")

# 1. Проверка пропущенных значений
print("Пропущенные значения:")
print(file.isnull().sum())

# 2. Количество образцов каждого вида ириса
print("\nКоличество образцов каждого вида:")
print(file["variety"].value_counts())

# 3. Pair plot для всех признаков
sns.pairplot(file, hue="variety")
plt.show()

# 4. Средние значения признаков для каждого вида
print("\nСредние значения признаков:")
print(file.groupby("variety").mean(numeric_only=True))

# 5. Box plot для Petal Length
sns.boxplot(
    x="variety",
    y="petal.length",
    data=file
)
```

```
plt.xlabel("Вид ириса")
plt.ylabel("Petal Length (cm)")
plt.title("Распределение длины лепестка по видам ириса")
plt.show()

# 6. Стандартизация данных
features = [
    "sepal.length",
    "sepal.width",
    "petal.length",
    "petal.width"
]

df_standardized = file.copy()

df_standardized[features] = (
    file[features] - file[features].mean()
) / file[features].std()

print("\nСтандартизированные данные:")
print(df_standardized)
```

```
Пропущенные значения:
sepal.length    0
sepal.width     0
petal.length    0
petal.width     0
variety         0
dtype: int64
Количество образцов каждого вида:
variety
Setosa        50
Versicolor    50
Virginica     50
Name: count, dtype: int64
Средние значения признаков:
            sepal.length  sepal.width  petal.length  petal.width
variety
Setosa             5.006        3.428         1.462        0.246
Versicolor         5.936        2.770         4.260        1.326
Virginica          6.588        2.974         5.552        2.026

Стандартизированные данные:
     sepal.length  sepal.width  petal.length  petal.width    variety
0       -0.897674     1.015602     -1.335752    -1.311052     Setosa
1       -1.139200    -0.131539     -1.335752    -1.311052     Setosa
2       -1.380727     0.327318     -1.392399    -1.311052     Setosa
```

```
3         -1.501490      0.097889      -1.279104     -1.311052      Setosa
4         -1.018437      1.245030      -1.335752     -1.311052      Setosa
..              ...           ...           ...           ...         ...
145        1.034539     -0.131539       0.816859      1.443994   Virginica
146        0.551486     -1.278680       0.703564      0.919223   Virginica
147        0.793012     -0.131539       0.816859      1.050416   Virginica
148        0.430722      0.786174       0.930154      1.443994   Virginica
149        0.068433     -0.131539       0.760211      0.788031   Virginica

[150 rows x 5 columns]
```



