МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
«БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ

ФАКУЛЬТЕТ ЭЛЕКТРОННО-ИНФОРМАЦИОННЫХ СИСТЕМ

Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №1

Специальность СУИ

Выполнил:
Кульбеда А. Ю.
студент группы АС-68

Проверил:
Крощенко А. А.
ст. преп. кафедры ИИТ,

«___» _____ 2026г.

Брест 2026

Цель работы: получить практические навыки работы с данными с использованием библиотек **Pandas** для манипуляции и **Matplotlib** для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Вариант 4

Задание 1. Загрузите данные и выведите информацию о типах столбцов.

```
import pandas as pd

df = pd.read_csv('winequality-white.csv', sep=';')

print("Первые 5 строк:")
print(df.head())

print("\nТипы столбцов:")
print(df.dtypes)
```

Вывод кода:

```
Первые 5 строк:
   fixed acidity  volatile acidity  citric acid  residual sugar  chlorides  ...  density    pH  sulphates  alcohol  quality
0            7.0              0.27         0.36            20.7      0.045  ...   1.0010  3.00       0.45      8.8        6
1            6.3              0.30         0.34             1.6      0.049  ...   0.9940  3.30       0.49      9.5        6
2            8.1              0.28         0.40             6.9      0.050  ...   0.9951  3.26       0.44     10.1        6
3            7.2              0.23         0.32             8.5      0.058  ...   0.9956  3.19       0.40      9.9        6
4            7.2              0.23         0.32             8.5      0.058  ...   0.9956  3.19       0.40      9.9        6

[5 rows x 12 columns]

Типы столбцов:
fixed acidity           float64
volatile acidity        float64
citric acid             float64
residual sugar          float64
chlorides               float64
free sulfur dioxide     float64
total sulfur dioxide    float64
density                 float64
pH                      float64
sulphates               float64
alcohol                 float64
quality                   int64
dtype: object
```

Задание 2. Преобразуйте целевую переменную quality в категориальную: "плохое" (<=4), "среднее" (5-6), "хорошее" (>=7).

```
import pandas as pd

df = pd.read_csv('winequality-white.csv', sep=';')

# функция, которая по числу возвращает категорию
def quality_cat(q):
    if q <= 4:
        return 'плохое'
    elif q <= 6:
        return 'среднее'
    else:
        return 'хорошее'
```

```
# создаём новый столбец, применив функцию к каждому значению quality
df['quality_cat'] = df['quality'].apply(quality_cat)

print(df[['quality', 'quality_cat']].head(10))
print()
print(df['quality_cat'].value_counts())
```

Вывод кода:

```
   quality quality_cat
0        6     среднее
1        6     среднее
2        6     среднее
3        6     среднее
4        6     среднее
5        6     среднее
6        6     среднее
7        6     среднее
8        6     среднее
9        6     среднее

quality_cat
среднее    3655
хорошее    1060
плохое      183
Name: count, dtype: int64
```

Задание 3. Постройте столбчатую диаграмму, показывающую количество вин каждой новой категории качества.

Код программы:

```
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv('winequality-white.csv', sep=';')

def quality_cat(q):
    if q <= 4:
        return 'плохое'
    elif q <= 6:
        return 'среднее'
    else:
        return 'хорошее'

df['quality_cat'] = df['quality'].apply(quality_cat)

# считаем количество в каждой категории
counts = df['quality_cat'].value_counts()

print(counts)

# строим диаграмму
plt.figure(figsize=(7, 5))
plt.bar(counts.index, counts.values)
```

```
plt.title('Количество вин по категориям качества')
plt.xlabel('Категория качества')
plt.ylabel('Количество вин')
plt.show()
```

Вывод программы:




```
quality_cat
среднее    3655
хорошее    1060
плохое      183
Name: count, dtype: int64
```

Задание 4. Проверьте корреляцию между fixed acidity и pH. Визуализируйте эту зависимость на диаграмме рассеяния.

Код программы:

```
import pandas as pd
import matplotlib.pyplot as plt

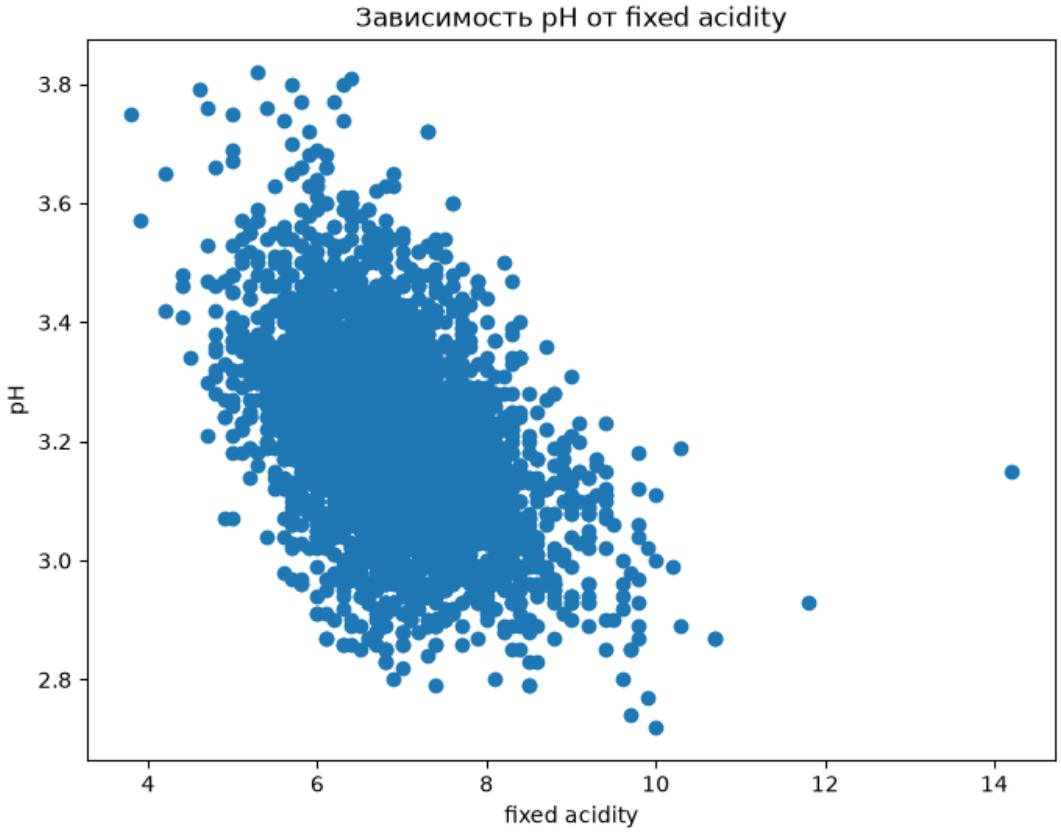
df = pd.read_csv('winequality-white.csv', sep=';')

# корреляция между двумя признаками
corr = df['fixed acidity'].corr(df['pH'])
print("Корреляция fixed acidity и pH:", round(corr, 3))

# диаграмма рассеяния
plt.figure(figsize=(8, 6))
plt.scatter(df['fixed acidity'], df['pH'])
```

```
plt.title('Зависимость pH от fixed acidity')
plt.xlabel('fixed acidity')
plt.ylabel('pH')
plt.show()
```

Вывод программы:




```
Корреляция fixed acidity и pH: -0.426
```

Задание 5. Найдите признак с наибольшим количеством выбросов, используя "ящик с усами" (box plot).

Код программы:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

df = pd.read_csv('winequality-white.csv', sep=';')

# числовые столбцы (исключаем quality, это целевая переменная)
cols = df.select_dtypes(include=[np.number]).columns.tolist()
cols.remove('quality')

# считаем выбросы по каждому признаку через IQR
outliers = {}
for col in cols:
    q1 = df[col].quantile(0.25)
```

```
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
    low = q1 - 1.5 * iqr
    high = q3 + 1.5 * iqr
    n = ((df[col] < low) | (df[col] > high)).sum()
    outliers[col] = n

outliers = pd.Series(outliers).sort_values(ascending=False)
print("Количество выбросов по признакам:")
print(outliers)

# признак с максимумом
print("\nБольше всего выбросов в:", outliers.idxmax(), "—",
outliers.max())

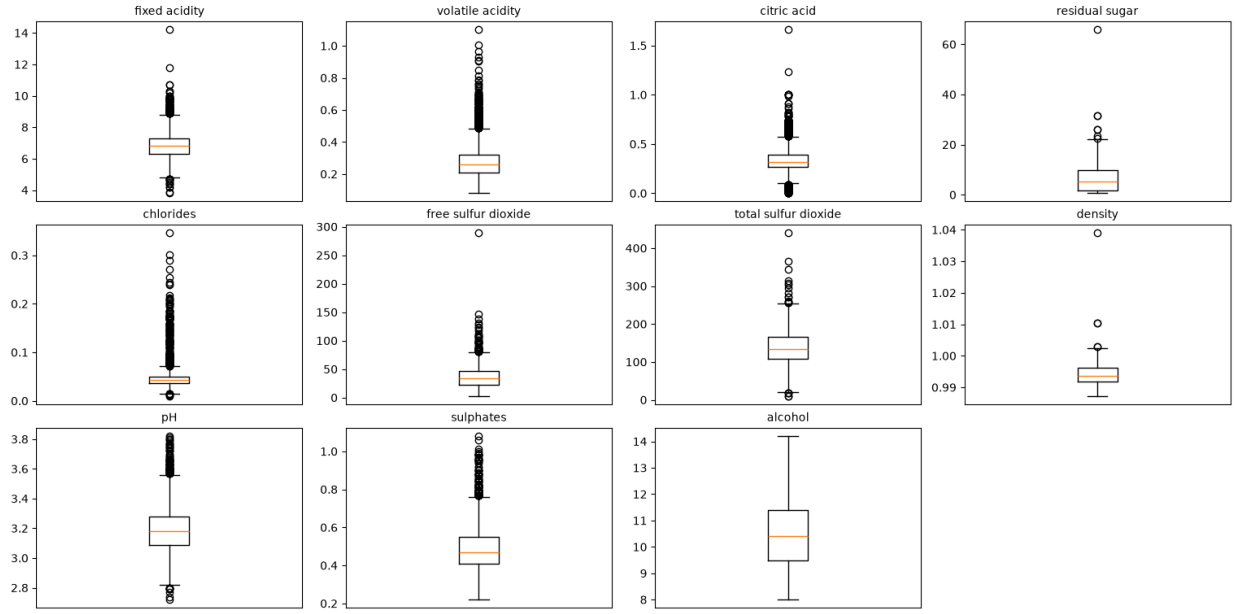
# box plot для всех признаков
fig, axes = plt.subplots(3, 4, figsize=(16, 10))
axes = axes.flatten()

for i, col in enumerate(cols):
    axes[i].boxplot(df[col])
    axes[i].set_title(col, fontsize=10)
    axes[i].set_xticks([])

# убираем пустой подграфик
for j in range(len(cols), len(axes)):
    axes[j].axis('off')

plt.tight_layout()
plt.show()
```

Вывод программы:



```
Количество выбросов по признакам:
citric acid             270
chlorides               208
volatile acidity        186
sulphates               124
fixed acidity           119
pH                       75
free sulfur dioxide      50
total sulfur dioxide     19
residual sugar            7
density                   5
alcohol                   0
dtype: int64

Больше всего выбросов в: citric acid — 270
```

Задание 6. Выполните стандартизацию всех числовых признаков.

Код программы:

```
import pandas as pd

df = pd.read_csv('winequality-white.csv', sep=';')

# числовые признаки без целевой переменной
cols = df.select_dtypes(include=['number']).columns.tolist()
cols.remove('quality')

# копируем датасет, чтобы исходный не портить
df_std = df.copy()

# стандартизация: z = (x - mean) / std
for col in cols:
    df_std[col] = (df_std[col] - df_std[col].mean()) /
df_std[col].std()

# проверка: среднее ~0, std ~1
print("Проверка после стандартизации:")
print(df_std[cols].agg(['mean', 'std']).round(4))

print("\nПервые 5 строк:")
print(df_std[cols].head())
```

Вывод программы:

```
Проверка после стандартизации:
      fixed acidity  volatile acidity  citric acid  residual sugar  chlorides  free sulfur dioxide  total sulfur dioxide  density   pH  sulphates  alcohol
mean           -0.0               0.0          0.0            -0.0        0.0                 -0.0                  -0.0      0.0 -0.0       -0.0     -0.0
std             1.0               1.0          1.0             1.0        1.0                  1.0                   1.0      1.0  1.0        1.0      1.0

Первые 5 строк:
   fixed acidity  volatile acidity  citric acid  residual sugar  chlorides  free sulfur dioxide  total sulfur dioxide   density        pH  sulphates   alcohol
0       0.172079         -0.081762     0.213258        2.821061  -0.035351             0.569873              0.744489  2.331274 -1.246794  -0.349149 -1.393010
1      -0.657434          0.215874     0.047996       -0.944669   0.147732            -1.252891             -0.149669 -0.009153  0.739953   0.001342 -0.824192
2       1.475600          0.017450     0.543783        0.100272   0.193503            -0.312109             -0.973236  0.358628  0.475053  -0.436771 -0.336633
3       0.409083         -0.478608    -0.117266        0.415726   0.559670             0.687471              1.120977  0.525802  0.011479  -0.787262 -0.499152
4       0.409083         -0.478608    -0.117266        0.415726   0.559670             0.687471              1.120977  0.525802  0.011479  -0.787262 -0.499152
```

Вывод: получены практические навыки загрузки, анализа, обработки и визуализации данных с помощью Pandas и Matplotlib; данные полностью подготовлены к следующему этапу — построению моделей машинного обучения.