Министерство образования Республики Беларусь

Учреждение образования

«Брестский государственный технический университет»

Факультет электронно-информационных систем

Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №1

Специальность АС-68

Выполнил:

Студент 3-го курса

Группы АС-68

М.Р. Мартысюк

Проверил:

А. А. Крощенко

Ст. преп. кафедры ИИТ,

«___»_____ 2026 г.

Брест 2026

Цель работы: Получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Вариант 6 Выполнить нормализацию или стандартизацию числовых признаков. Выборка Heart Disease. Содержит медицинские данные пациентов, такие как возраст, пол, уровень холестерина, и наличие заболевания сердца.

Задачи:

1. Загрузите данные и выведите информацию о них. Проверьте на наличие пропусков.
2. Постройте столбчатую диаграмму, сравнивающую количество здоровых и больных пациентов.
3. Создайте диаграмму рассеяния, показывающую зависимость максимального пульса (thalach) от возраста (age). Раскрасьте точки в зависимости от наличия болезни.
4. Преобразуйте признак sex (0 = женщина, 1 = мужчина) в более читаемый формат с категориями 'female' и 'male', а затем примените к нему One-Hot Encoding.
5. Рассчитайте средний уровень холестерина (chol) для больных и здоровых пациентов.
6. Выполните нормализацию признаков age, trestbps, chol и thalach.

Код программы:

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.preprocessing import MinMaxScaler
import os
os.chdir(os.path.dirname(os.path.abspath(__file__)))

# 1. Загрузка данных и проверка пропусков
df = pd.read_csv('heart.csv')
print(df.head())
print("\nПропуски в данных:", df.isnull().sum().sum())

# 2. Статистический анализ
print("\nСредние значения:")
print(df.mean(numeric_only=True).round(2))
print("\nМедианы:")
print(df.median(numeric_only=True).round(2))
print("\nСтд. отклонения:")
print(df.std(numeric_only=True).round(2))

# 3. Обработка пропусков
if df.isnull().sum().sum() > 0:
    num_cols = df.select_dtypes(include='number').columns
    df[num_cols] = df[num_cols].fillna(df[num_cols].median())
    print("\nПропуски заполнены медианой")
else:
```

```
    print("Пропусков нет — обработка не требуется")

# 4. One-Hot Encoding для sex
df['sex'] = df['sex'].map({0: 'female', 1: 'male'})
df = pd.get_dummies(df, columns=['sex'], prefix='sex', dtype=int)

# 5. Средний холестерин по группам
mean_chol = df.groupby('target')['chol'].mean().round(2)
mean_chol.index = ['Здоровые', 'Больные']
print("\nСредний холестерин:\n", mean_chol.to_string())

# 6. Нормализация
cols = ['age', 'trestbps', 'chol', 'thalach']
df[cols] = MinMaxScaler().fit_transform(df[cols])

# --- ГРАФИКИ ---
# Столбчатая
counts = df['target'].value_counts().sort_index()
plt.figure(figsize=(6, 4))
plt.bar(['Здоровые', 'Больные'], counts.values, color=['#4CAF50',
'#E53935'])
plt.title('Распределение пациентов')
for i, v in enumerate(counts.values):
    plt.text(i, v + 2, str(v), ha='center', fontweight='bold')
plt.show()

# Scatter plot
plt.figure(figsize=(8, 5))
plt.scatter(df[df['target'] == 0]['age'], df[df['target'] ==
0]['thalach'],
            c='#4CAF50', label='Здоровые', alpha=0.7, edgecolors='k')
plt.scatter(df[df['target'] == 1]['age'], df[df['target'] ==
1]['thalach'],
            c='#E53935', label='Больные', alpha=0.7, edgecolors='k')
plt.xlabel('Возраст'); plt.ylabel('Максимальный пульс')
plt.title('Зависимость пульса от возраста'); plt.legend();
plt.grid(alpha=0.3)
plt.show()

# Гистограмма
plt.figure(figsize=(8, 5))
plt.hist(df['chol'], bins=30, color='steelblue', edgecolor='black')
plt.xlabel('Холестерин'); plt.ylabel('Частота')
plt.title('Распределение холестерина')
plt.show()
```

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
0	63	1	3	145	233	1	0	150	0	2.3	0	0	1	1
1	37	1	2	130	250	0	1	187	0	3.5	0	0	2	1
2	41	0	1	130	204	0	0	172	0	1.4	2	0	2	1
3	56	1	1	120	236	0	1	178	0	0.8	2	0	2	1
4	57	0	0	120	354	0	1	163	1	0.6	2	0	2	1

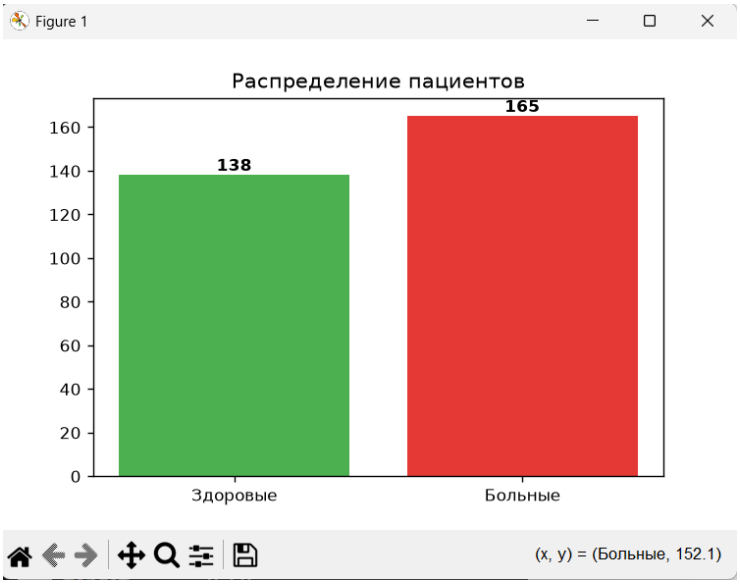
```
Пропуски в данных: 0
```

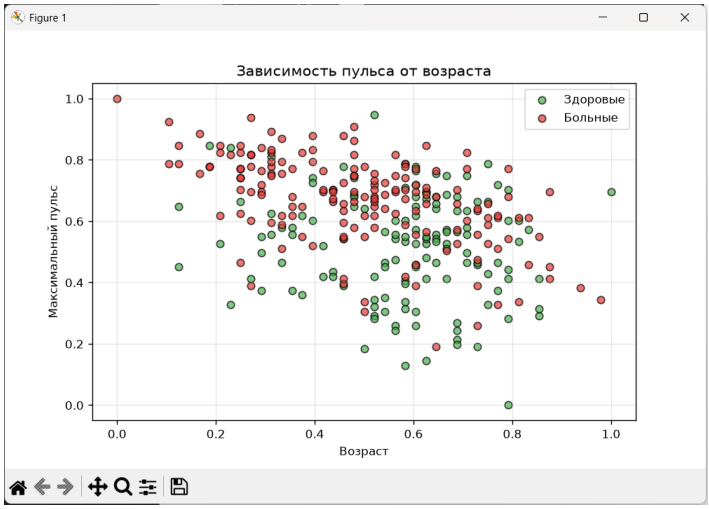
```
Средние значения:
age         54.37
sex          0.68
cp           0.97
trestbps   131.62
chol       246.26
fbs          0.15
restecg      0.53
thalach    149.65
exang        0.33
oldpeak      1.04
slope        1.40
ca           0.73
thal         2.31
target       0.54
dtype: float64

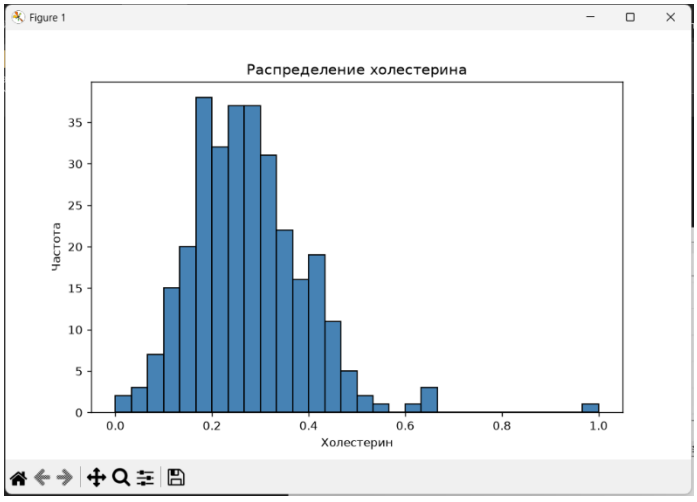
Медианы:
age         55.0
sex          1.0
cp           1.0
trestbps   130.0
chol       240.0
fbs          0.0
restecg      1.0
thalach    153.0
exang        0.0
oldpeak      0.8
slope        1.0
ca           0.0
thal         2.0
target       1.0
dtype: float64
```

```
Стд. отклонения:
age          9.08
sex          0.47
cp           1.03
trestbps    17.54
chol        51.83
fbs          0.36
restecg      0.53
thalach     22.91
exang        0.47
oldpeak      1.16
slope        0.62
ca           1.02
thal         0.61
target       0.50
dtype: float64
Пропусков нет — обработка не требуется

Средний холестерин:
 Здоровые    251.09
Больные      242.23
```







Вывод: получил практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научился выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.