Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Факультет электронно-информационных систем
Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №3

Специальность АС-68

Выполнил:
Студент 3-го курса
Группы АС-68
Г. В. Пошвенчук
Проверил:
А. А. Крощенко
Ст. преп. кафедры ИИТ,
«___»_____ 2026 г.

Брест 2026

Цель: На практике сравнить работу нескольких алгоритмов классификации, таких как **метод k-ближайших соседей (k-NN)**, **деревья решений** и **метод опорных векторов (SVM)**. Научиться подбирать гиперпараметры моделей и оценивать их влияние на результат.

Задачи:

1. Загрузить датасет по варианту;
2. Разделить данные на обучающую и тестовую выборки;
3. Обучить на обучающей выборке три модели: k-NN, Decision Tree и SVM;
4. Для модели k-NN исследовать, как меняется качество при разном количестве соседей (k);
5. Оценить точность каждой модели на тестовой выборке;
6. Сравнить результаты, сделать выводы о применимости каждого метода для данного набора данных.

Вариант 6

- `Pima Indians Diabetes`
- Предсказать наличие диабета у пациенток
- **Задания:**
    1. Загрузите данные и стандартизируйте их;
    2. Разделите выборку в соотношении 70/30;
    3. Обучите модели k-NN (с `k=5`), Decision Tree (с `max_depth=4`) и SVM (с линейным ядром);
    4. Сравните производительность моделей с помощью метрики `recall` для положительного класса (наличие диабета).
    5. Обоснуйте, какой из алгоритмов предпочтительнее для данной медицинской задачи.

Код программы:

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import make_pipeline
from sklearn.neighbors import KNeighborsClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.svm import SVC
from sklearn.metrics import recall_score, accuracy_score

# 1. Загрузка данных
columns = ['Pregnancies', 'Glucose', 'BloodPressure', 'SkinThickness',
           'Insulin', 'BMI', 'DiabetesPedigree', 'Age', 'Outcome']
df = pd.read_csv('pima-indians-diabetes.csv', header=None, names=columns, comment='#')

X = df.drop(columns=['Outcome'])
y = df['Outcome']

print(f"Всего записей: {X.shape[0]}, из них признаков: {X.shape[1]}")

# 2. Разделение выборки (70/30)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=123, stratify=y
)

# 3. Создание моделей
models = {
    "k-NN": make_pipeline(
```

```
        StandardScaler(),
        KNeighborsClassifier(n_neighbors=5)
    ),
    "Decision Tree": make_pipeline(
        StandardScaler(),
        DecisionTreeClassifier(max_depth=4, random_state=123)
    ),
    "SVM": make_pipeline(
        StandardScaler(),
        SVC(kernel="linear", random_state=123)
    )
}

results = {}

# 4. Обучение и вывод метрик
print("\nОценка классификаторов:")
print("Модель           | Accuracy | Recall (Диабет)")
print("-" * 47)
for name, model in models.items():
    model.fit(X_train, y_train)
    predictions = model.predict(X_test)

    acc = accuracy_score(y_test, predictions)
    rec = recall_score(y_test, predictions)

    results[name] = (acc, rec)
    print(f"{name:<15} | {acc:.4f}   | {rec:.4f}")

# 5. Исследование параметра k для k-NN
print("\nИсследование качества k-NN при разном количестве соседей:")
for k in [1, 3, 5, 7, 9, 11, 13, 15]:
    model = make_pipeline(StandardScaler(), KNeighborsClassifier(n_neighbors=k))
    model.fit(X_train, y_train)
    acc = accuracy_score(y_test, model.predict(X_test))

    mark = " (базовый из задания)" if k == 5 else ""
    print(f"k={k:<2} -> Accuracy = {acc:.4f}{mark}")

# 6. Финальное сравнение
print("\nТочности моделей:")
for name, (acc, rec) in sorted(results.items(), key=lambda item: item[1][0],
reverse=True):
    print(f"{name}: {acc:.4f}")

best_model = max(results, key=lambda k: (results[k][0], results[k][1]))

best_acc = results[best_model][0]
best_rec = results[best_model][1]

print(f"\nЛучшая базовая модель: {best_model} (Accuracy = {best_acc:.4f}, Recall =
{best_rec:.4f})")
```

Результат:

```
Всего записей: 768, из них признаков: 8

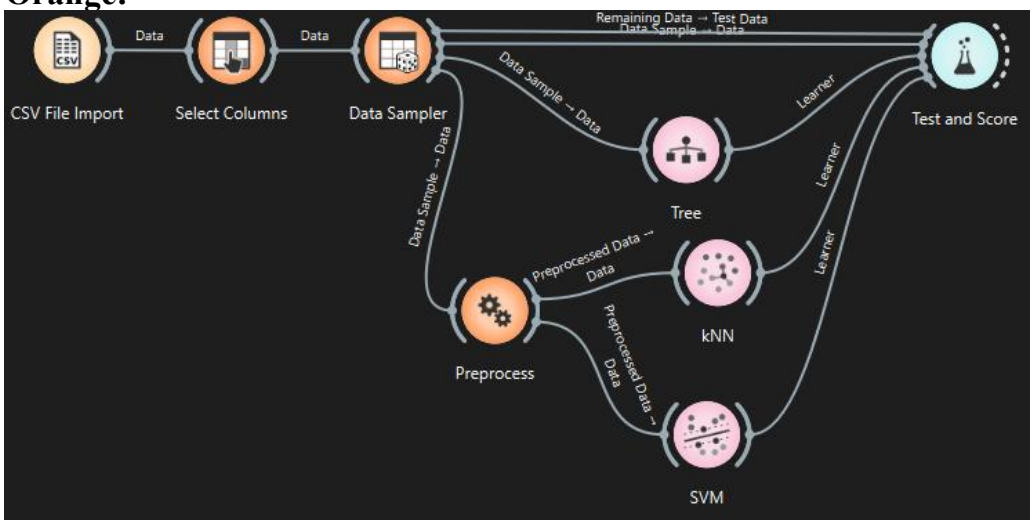
Оценка классификаторов:
Модель          | Accuracy | Recall (Диабет)
-----------------------------------------------
k-NN            | 0.7576   | 0.5309
Decision Tree   | 0.7576   | 0.6173
SVM             | 0.7446   | 0.5185

Исследование качества k-NN при разном количестве соседей:
При k=1  -> Accuracy = 0.7359
При k=3  -> Accuracy = 0.7446
При k=5  -> Accuracy = 0.7576 (базовый из задания)
При k=7  -> Accuracy = 0.7706
При k=9  -> Accuracy = 0.7532
При k=11 -> Accuracy = 0.7662
При k=13 -> Accuracy = 0.7749
При k=15 -> Accuracy = 0.7749

Точности моделей:
k-NN: 0.7576
Decision Tree: 0.7576
SVM: 0.7446

Лучшая базовая модель: Decision Tree (Accuracy = 0.7576, Recall = 0.6173)
```

Orange:



Evaluation results for target 1

Model	Train	Test	AUC	CA	F1	Prec	Recall	MCC	Spec	LogLoss
SVM	0.035	0.003	0.795	0.748	0.580	0.690	0.500	0.417	0.880	0.536
Tree	0.009	0.000	0.728	0.722	0.619	0.591	0.650	0.402	0.760	1.913
kNN	0.009	0.008	0.747	0.730	0.569	0.641	0.512	0.382	0.847	1.709

Вывод: на практике сравнил работу нескольких алгоритмов классификации, таких как метод k-ближайших соседей (k-NN), деревья решений и метод опорных векторов (SVM). Научился подбирать гиперпараметры моделей и оценивать их влияние на результат.