

Министерство образования Республики Беларусь
Учреждение образования
«Брестский Государственный технический университет»
Кафедра ИИТ

Лабораторная работа №1
По дисциплине «ОМО»

Выполнил:
Студент 3-го курса
Группы АС-68
Цветков А.А.
Проверил:
Крощенко А.А.

Цель работы: Получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Ход работы

Вариант 9

Выборка Melbourne Housing Market. Содержит данные о продажах домов в Мельбурне, включая цену, количество комнат, район и т.д.

Задачи:

1. Загрузите данные. Найдите столбец с наибольшим количеством пропущенных значений и удалите его.
2. Удалите все строки, где отсутствует значение цены (Price).
3. Постройте гистограмму распределения цен на недвижимость.
4. Рассчитайте среднюю цену за дом для 5 самых популярных пригородов (Suburb).
5. Создайте новый признак PropertyAge на основе года постройки (YearBuilt).
6. Преобразуйте признак Type (тип недвижимости) в числовой формат с помощью One-Hot Encoding.

Код программы :

```
import datetime
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns

sns.set_theme(style="whitegrid")

# 1. Загрузка данных и удаление столбца с наибольшим количеством пропусков
file_path = r"C:\ОМО\datasets_lab1\Melbourne_housing.csv"
df = pd.read_csv(file_path, low_memory=False)

print("--- ЗАДАНИЕ 1 ---")
max_missing_col = df.isnull().sum().idxmax()
print(f"Столбец с наибольшим количеством пропусков: {max_missing_col}")
df = df.drop(columns=[max_missing_col])

# 2. Удаление строк, где отсутствует значение цены (Price)
print("\n--- ЗАДАНИЕ 2 ---")
print(f"Размер датасета ДО удаления строк без цены: {df.shape}")
df = df.dropna(subset=["Price"])
print(f"Размер датасета ПОСЛЕ удаления строк без цены: {df.shape}")

# 3. Построение гистограммы распределения цен на недвижимость
plt.figure(figsize=(8, 5))
sns.histplot(df["Price"], bins=40, color="steelblue", kde=True, edgecolor="black")
plt.title("Распределение цен на недвижимость")
plt.xlabel("Цена (Price)")
plt.ylabel("Частота")
plt.tight_layout()
```

```

plt.show()

# 4. Расчет средней цены за дом для 5 самых популярных пригородов
(Suburb)
print("\n--- ЗАДАНИЕ 4 ---")
top_5_suburbs = df["Suburb"].value_counts().head(5).index
avg_price_top_5 = (
    df[df["Suburb"].isin(top_5_suburbs)].groupby("Suburb")["Price"].mean()
)
print("Средняя цена в ТОП-5 пригородах:")
print(avg_price_top_5)

# 5. Создание нового признака PropertyAge на основе года постройки
(YearBuilt)
current_year = datetime.datetime.now().year
df["PropertyAge"] = current_year - df["YearBuilt"]

# 6. Преобразование признака Type в числовой формат с помощью One-Hot
Encoding
df = pd.get_dummies(df, columns=["Type"], prefix="Type", dtype=int)

print("\n--- ЗАДАНИЕ 5 и 6 (ПРОВЕРКА ИТОВОВЫХ СТОЛБЦОВ) ---")
print(df[["PropertyAge", "Type_h", "Type_t", "Type_u"]].head())

```

В данном коде изложены все задания данной лабораторной работы (в методах заданий). Разберем результаты вывода данной программы.

Вывод результатов первого и второго задания:


```

--- ЗАДАНИЕ 1 ---
Столбец с наибольшим количеством пропусков: BuildingArea

--- ЗАДАНИЕ 2 ---
Размер датасета ДО удаления строк без цены: (34857, 21)
Размер датасета ПОСЛЕ удаления строк без цены: (27247, 21)

```

Вывод результатов 3-его задания:



Вывод результатов 4 - 6 задания:

```
--- ЗАДАНИЕ 4 ---
Средняя цена в ТОП-5 пригородах:
Suburb
Bentleigh East    1.131418e+06
Brunswick         9.779888e+05
Preston           8.778699e+05
Reservoir         6.911045e+05
Richmond          1.067585e+06
Name: Price, dtype: float64

--- ЗАДАНИЕ 5 и 6 (ПРОВЕРКА ИТОГОВЫХ СТОЛБЦОВ) ---
   PropertyAge  Type_h  Type_t  Type_u
1          10.0       0       1       0
2         126.0       1       0       0
3           NaN       1       0       0
5          96.0       1       0       0
6          13.0       1       0       0
```

Вывод: мы приобрели практические знания по работе с Pandas, Matplotlib, а также научились анализировать датасеты для дальнейшего обучения моделей на их основе.