МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
<БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ>

ФАКУЛЬТЕТ ЭЛЕКТРОННО-ИНФОРМАЦИОННЫХ СИСТЕМ

Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №3

Специальность АС-68

Выполнил
А. В. Венско,
студент группы АС-68

Проверил
А. А. Крощенко,
ст. преп. кафедры ИИТ,
«___> _____2026 г.

Брест 2026

Цель: На практике сравнить работу нескольких алгоритмов классификации, таких как метод k-ближайших соседей (k-NN), деревья решений и метод опорных векторов (SVM). Научиться подбирать гиперпараметры моделей и оценивать их влияние на результат.

Вариант 2

- `Breast Cancer Wisconsin`
- Определить, является ли опухоль злокачественной (`malignant`) или доброкачественной (`benign`);
- **Задания:**
    1. Загрузите данные и выполните стандартизацию признаков;
    2. Разделите данные на обучающую и тестовую части;
    3. Обучите три классификатора: k-NN, Decision Tree и SVM;
    4. Для каждой модели постройте матрицу ошибок и рассчитайте метрики `precision`, `recall` и `F1-score` для класса "злокачественная опухоль";
    5. Сравните модели и укажите, какая из них наиболее надежна для минимизации ложноотрицательных прогнозов (когда злокачественная опухоль определяется как доброкачественная).

Выполнение:

Код программы

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.svm import SVC
from sklearn.metrics import (
    accuracy_score,
    confusion_matrix,
    precision_score,
    recall_score,
    f1_score
)

print("   Запуск задачи классификации (Breast Cancer Wisconsin)")

df = pd.read_csv("breast_cancer.csv")

df = df.drop(
    columns=["id", "Unnamed: 32"],
    errors="ignore"
)

X = df.drop("diagnosis", axis=1)
y = (df["diagnosis"] == "M").astype(int)

print("Количество записей:", len(df))
print("Количество признаков:", X.shape[1])
print("Доброкачественные опухоли:", (y == 0).sum())
print("Злокачественные опухоли:", (y == 1).sum())

X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=42,
```

```
    stratify=y
)

scaler = StandardScaler()

X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

models = {
    "k-NN": KNeighborsClassifier(n_neighbors=5),
    "Decision Tree": DecisionTreeClassifier(random_state=42),
    "SVM": SVC(kernel="rbf", C=1.0, gamma="scale")
}

results = []

for name, model in models.items():

    model.fit(X_train, y_train)
    y_pred = model.predict(X_test)

    accuracy = accuracy_score(y_test, y_pred)
    precision = precision_score(y_test, y_pred)
    recall = recall_score(y_test, y_pred)
    f1 = f1_score(y_test, y_pred)

    cm = confusion_matrix(y_test, y_pred, labels=[0, 1])

    tn, fp, fn, tp = cm.ravel()

    results.append({
        "Модель": name,
        "Accuracy": accuracy,
        "Precision": precision,
        "Recall": recall,
        "F1-score": f1,
        "False Negatives": fn
    })

    print(f"\n{name}")
    print(f"Accuracy:  {accuracy:.4f}")
    print(f"Precision: {precision:.4f}")
    print(f"Recall:    {recall:.4f}")
    print(f"F1-score:  {f1:.4f}")

    print("\nМатрица ошибок:")
    print(cm)

    print("\nАнализ матрицы ошибок:")
    print(f"TN: {tn}")
    print(f"FP: {fp}")
    print(f"FN: {fn}")
    print(f"TP: {tp}")

    plt.figure(figsize=(6, 5))

    plt.imshow(
        cm,
        interpolation="nearest",
        cmap=plt.cm.Blues
    )

    plt.title(f"Матрица ошибок — {name}")
    plt.colorbar()

    plt.xticks(
        [0, 1],
        ["Benign", "Malignant"]
```

```
    )

    plt.yticks(
        [0, 1],
        ["Benign", "Malignant"]
    )

    thresh = cm.max() / 2

    for i in range(2):
        for j in range(2):
            plt.text(
                j,
                i,
                str(cm[i, j]),
                ha="center",
                va="center",
                color="white" if cm[i, j] > thresh else "black"
            )

    plt.xlabel("Предсказанный класс")
    plt.ylabel("Фактический класс")
    plt.tight_layout()
    plt.show()

results = pd.DataFrame(results)

print("\nСРАВНЕНИЕ МОДЕЛЕЙ")
print(results.to_string(
    index=False,
    float_format=lambda x: f"{x:.4f}"
))

best_model = results.sort_values(
    by=["False Negatives", "Recall"],
    ascending=[True, False]
).iloc[0]

print("\nНАИБОЛЕЕ НАДЕЖНАЯ МОДЕЛЬ")
print(best_model["Модель"])
print("Количество ложноотрицательных прогнозов:",
      int(best_model["False Negatives"]))
print(f"Recall: {best_model['Recall']:.4f}")
```

Результат:

Запуск задачи классификации (Breast Cancer Wisconsin)
Количество записей: 569
Количество признаков: 30
Доброкачественные опухоли: 357
Злокачественные опухоли: 212

k-NN
Accuracy: 0.9561
Precision: 0.9744
Recall: 0.9048
F1-score: 0.9383

Матрица ошибок:
[[71 1]
 [4 38]]

Анализ матрицы ошибок:
TN: 71
FP: 1
FN: 4

TP: 38

Decision Tree
Accuracy: 0.9298
Precision: 0.9048
Recall: 0.9048
F1-score: 0.9048

Матрица ошибок:
[[68 4]
 [4 38]]

Анализ матрицы ошибок:
TN: 68
FP: 4
FN: 4
TP: 38

SVM
Accuracy: 0.9737
Precision: 1.0000
Recall: 0.9286
F1-score: 0.9630

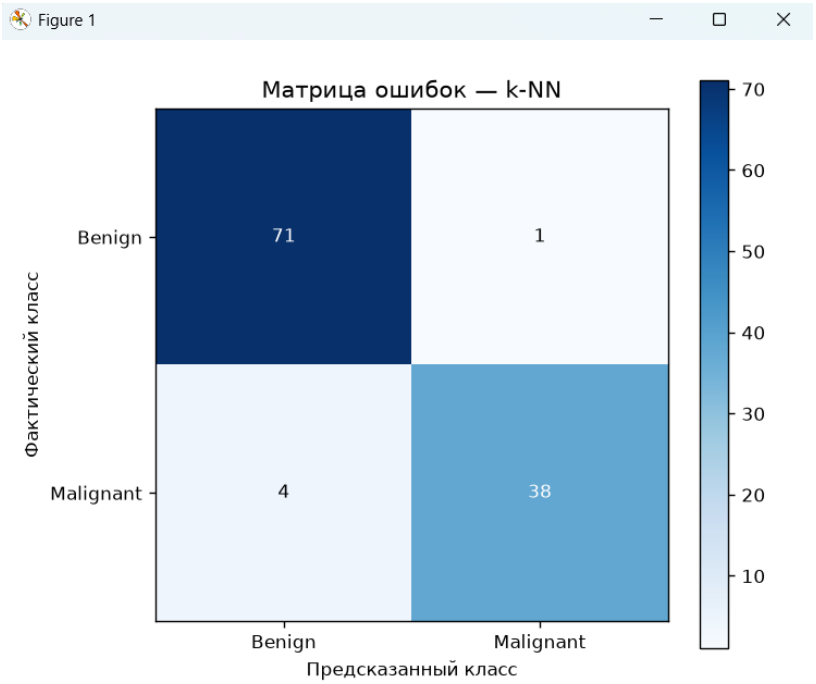
Матрица ошибок:
[[72 0]
 [3 39]]

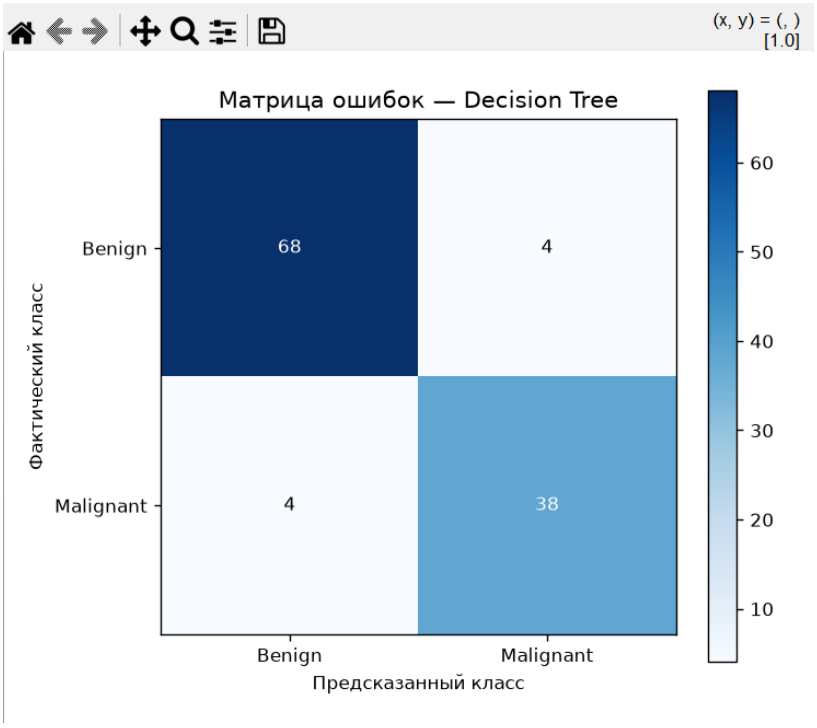
Анализ матрицы ошибок:
TN: 72
FP: 0
FN: 3
TP: 39

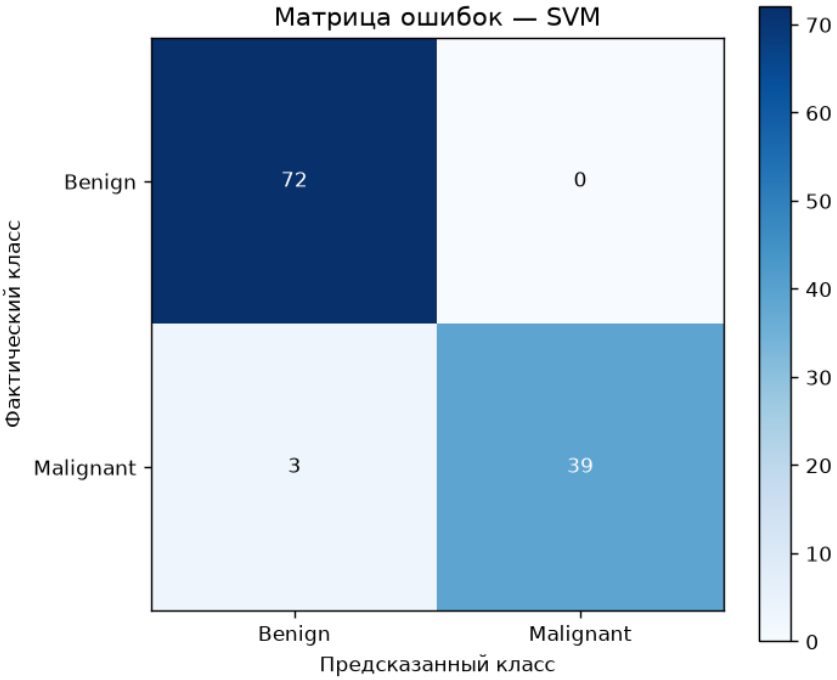
СРАВНЕНИЕ МОДЕЛЕЙ

Модель	Accuracy	Precision	Recall	F1-score	False Negatives
k-NN	0.9561	0.9744	0.9048	0.9383	4
Decision Tree	0.9298	0.9048	0.9048	0.9048	4
SVM	0.9737	1.0000	0.9286	0.9630	3

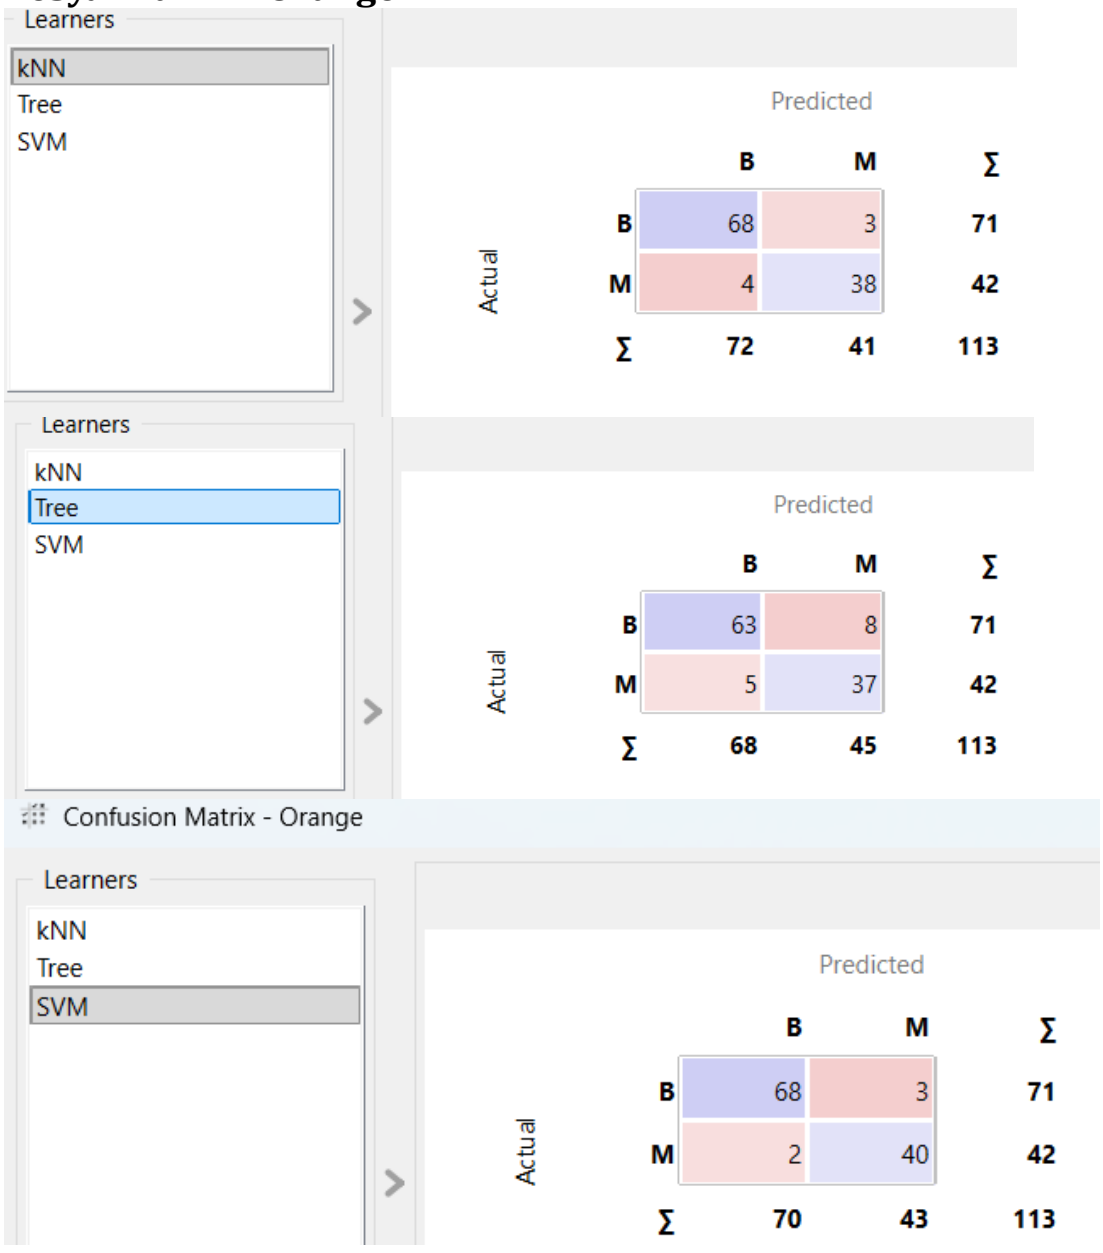
НАИБОЛЕЕ НАДЕЖНАЯ МОДЕЛЬ
SVM
Количество ложноотрицательных прогнозов: 3
Recall: 0.9286

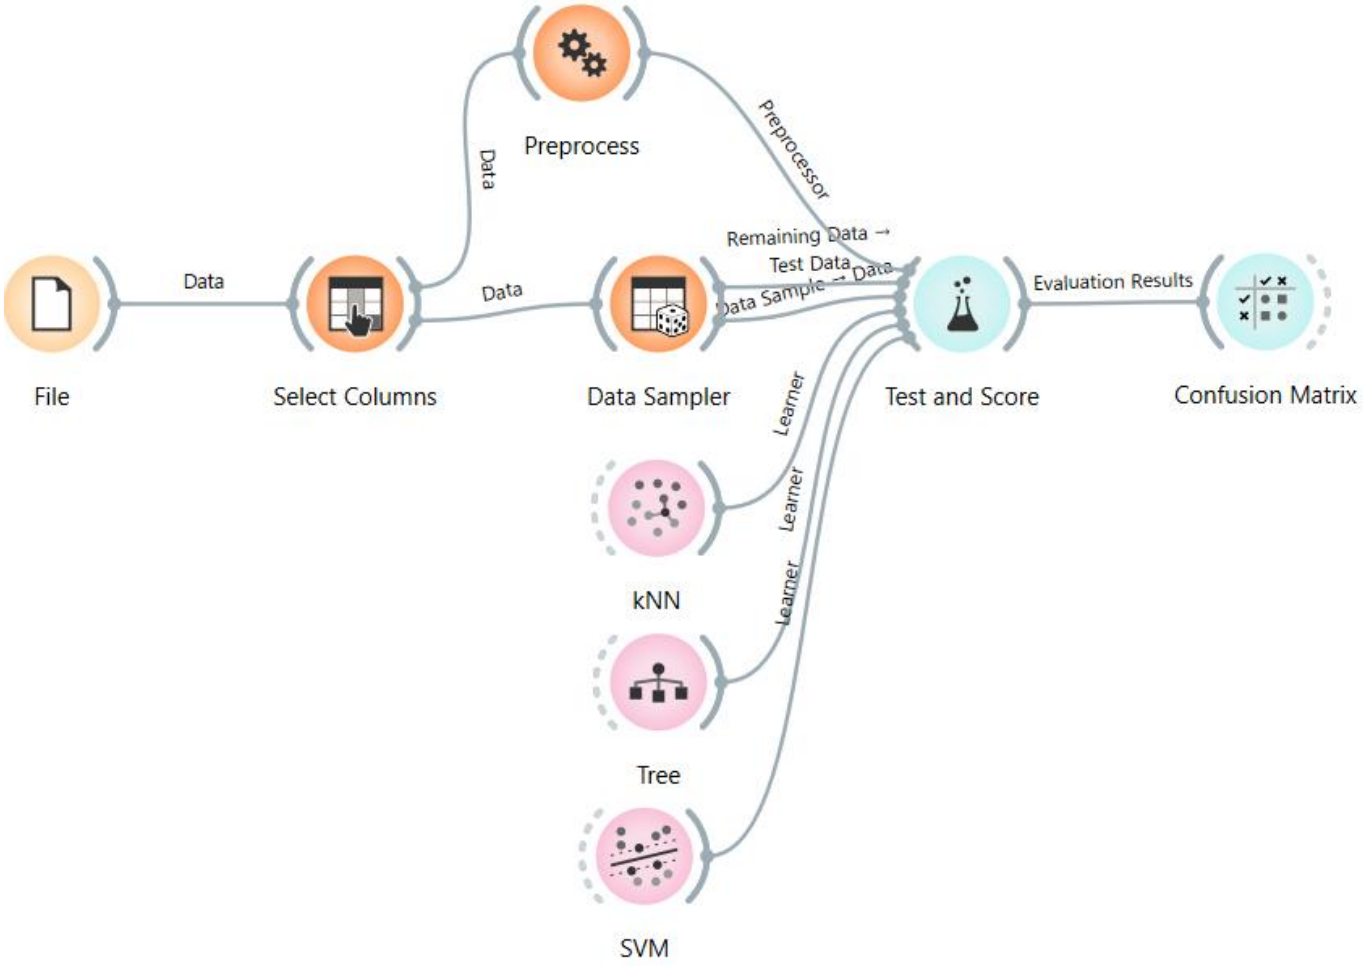

Figure 1
Матрица ошибок — k-NN
Benign
Malignant
Фактический класс
71
1
4
38
Benign
Malignant
Предсказанный класс
70
60
50
40
30
20
10


(x, y) = (,)
[1.0]
Матрица ошибок — Decision Tree
Benign
Malignant
Фактический класс
68
4
4
38
Benign
Malignant
Предсказанный класс
60
50
40
30
20
10



Результаты в Orange:





Вывод: В ходе лабораторной работы была выполнена классификация опухолей молочной железы с использованием трёх алгоритмов машинного обучения: k-NN, Decision Tree и SVM. Для всех моделей была выполнена стандартизация признаков и оценка качества на тестовой выборке. Наилучший результат показал алгоритм SVM, значение Accuracy которого составило 0,9737, Precision — 1,0000, Recall — 0,9286, а F1-score — 0,9630. Кроме того, SVM допустила наименьшее количество ложноотрицательных прогнозов — 3 случая, тогда как k-NN и Decision Tree допустили по 4 ошибки. Таким образом, среди рассмотренных моделей SVM оказалась наиболее эффективной для минимизации случаев, когда злокачественная опухоль ошибочно определяется как доброкачественная.