

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №1
По дисциплине: «Основы машинного обучения»
Тема: «Знакомство с анализом данных: предварительная обработка и визуализация»

Выполнил:
Студент 3-го курса
Группы АС-68
Ярмолинский И.В.
Проверил:
А. А. Крощенко
Ст. преп. кафедры ИИТ
«__» _____ 2026

Цель: Получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Вариант 10

1. Загрузите данные и выведите информацию о них.

В работе используется набор данных German Credit. Данные загружаются в DataFrame библиотеки Pandas. После загрузки выводятся размер набора данных, первые строки и информация о столбцах.

Код программы:

```
import pandas as pd

# Загрузка данных
df = pd.read_csv("german_credit.csv")

print("Размер данных:", df.shape)

print("\nПервые строки:")
print(df.head())

print("\nИнформация о данных:")
df.info()
```

```
Информация о данных:
<class 'pandas.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 21 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   default                               1000 non-null   int64
1   account_check_status                 1000 non-null   str
2   duration_in_month                    1000 non-null   int64
3   credit_history                        1000 non-null   str
4   purpose                              1000 non-null   str
5   credit_amount                        1000 non-null   int64
6   savings                              1000 non-null   str
7   present_emp_since                    1000 non-null   str
8   installment_as_income_perc           1000 non-null   int64
9   personal_status_sex                  1000 non-null   str
10  other_debtors                        1000 non-null   str
11  present_res_since                    1000 non-null   int64
12  property                              1000 non-null   str
13  age                                  1000 non-null   int64
14  other_installment_plans               1000 non-null   str
15  housing                              1000 non-null   str
16  credits_this_bank                     1000 non-null   int64
17  job                                   1000 non-null   str
18  people_under_maintenance              1000 non-null   int64
19  telephone                            1000 non-null   str
20  foreign_worker                       1000 non-null   str
dtypes: int64(8), str(13)
memory usage: 164.2 KB
```

2. Проанализируйте распределение цели кредита (Purpose). Визуализируйте 5 самых популярных целей.

Для анализа используется столбец purpose, содержащий информацию о цели получения кредита. Определяются пять наиболее популярных целей и строится столбчатая диаграмма.

Код программы:

```
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv("german_credit.csv")

# Находим 5 самых популярных целей кредита
purpose = df["purpose"].value_counts().head(5)

# Перевод названий на русский язык
```

```


names = {
    "domestic appliances": "Бытовая техника",
    "car (new)": "Новый автомобиль",
    "radio/television": "Радио/телевизор",
    "car (used)": "Подержанный автомобиль",
    "business": "Бизнес"
}

purpose.index = purpose.index.map(names)

print("\nТоп-5 целей кредита:")
print(purpose)

purpose.plot(kind="bar", title="Топ-5 целей кредита")
plt.xlabel("Цель кредита")
plt.ylabel("Количество")
plt.xticks(rotation=30)
plt.tight_layout()
plt.show()

```



3. Преобразуйте категориальные признаки Sex и Housing в числовой формат.

В исходном наборе данных отдельного столбца Sex нет: информация о поле содержится в столбце personal_status_sex. Из него извлекается значение male или female. Для признака Housing используется числовое кодирование.

Код программы:

```

import pandas as pd

df = pd.read_csv("german_credit.csv")

# Преобразование пола заемщика
df["Sex"] = df["personal_status_sex"].str.extract("(male|female)")[0].map({
    "male": 0,
    "female": 1
})

# Преобразование типа жилья
df["Housing"] = df["housing"].map({
    "own": 0,
    "rent": 1,
    "for free": 2
})

print("\nЗакодированные признаки Sex и Housing:")
print(df[["Sex", "Housing"]].head())

```

Закодированные Sex и Housing:

	Sex	Housing
0	0	0
1	1	0
2	0	0
3	0	2
4	0	2

4. Постройте "ящик с усами" для Credit amount, чтобы сравнить суммы кредитов у "хороших" и "плохих" заемщиков.

Для сравнения сумм кредитов используется столбец credit_amount. По столбцу default заемщики разделяются на две группы: 0 — хорошие заемщики, 1 — плохие заемщики.

Код программы:

```
import pandas as pd
import matplotlib.pyplot as plt


df = pd.read_csv("german_credit.csv")

# Разделяем заемщиков на две группы
good = df[df["default"] == 0]["credit_amount"]
bad = df[df["default"] == 1]["credit_amount"]

# Построение box plot
plt.figure()
plt.boxplot(
    [good, bad],
    tick_labels=["Хорошие", "Плохие"]
)

plt.title("Суммы кредитов")
plt.xlabel("Тип заемщика")
plt.ylabel("Сумма кредита")

plt.show()
```



5. Создайте сводную таблицу, показывающую средний возраст (Age) и среднюю длительность кредита (Duration) для каждой категории кредитной истории (Credit history).

Для анализа создается сводная таблица. В качестве индекса используется credit_history, а для каждой категории рассчитываются средний возраст заемщика и средняя длительность кредита.

Код программы:

```
import pandas as pd

df = pd.read_csv("german_credit.csv")

# Создание сводной таблицы
table = df.pivot_table(
    index="credit_history",
    values=["age", "duration_in_month"],
    aggfunc="mean"
)

print("\nСредний возраст и длительность кредита:")
print(table.round(2))
```

```
Средний возраст и длительность кредита:

               age  duration_in_month
credit_history
all credits at this bank paid back duly    36.27         22.69
critical account/ other credits existing (not a...  38.44         19.49
delay in paying off in the past             36.14         26.22
existing credits paid back duly till now      33.88         20.11
no credits taken/ all credits paid back duly  34.30         27.88
```

6. Нормализуйте числовые столбцы Age, Credit amount, Duration.

Выполняется Min-Max нормализация трех числовых признаков: age, credit_amount и duration_in_month. После нормализации значения признаков приводятся к диапазону от 0 до 1.

Код программы:

```
import pandas as pd

df = pd.read_csv("german_credit.csv")

# Нормализация числовых столбцов
for col in ["age", "credit_amount", "duration_in_month"]:
    df[col] = (
        df[col] - df[col].min()
    ) / (
        df[col].max() - df[col].min()
    )

print("\nНормализованные данные:")
print(df[["age", "credit_amount", "duration_in_month"]].head())
```

```
Нормализованные данные:

   age  credit_amount  duration_in_month
0  0.857143      0.050567         0.029412
1  0.053571      0.313690         0.647059
2  0.535714      0.101574         0.117647
3  0.464286      0.419941         0.558824
4  0.607143      0.254209         0.294118
□
```

Вывод: Получил практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научился выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.