Министерство образования Республики Беларусь

Учреждение образования

«Брестский государственный технический университет»

Факультет электронно-информационных систем

Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №2

Специальность АС-68

Выполнил:

Студент 3-го курса

Группы АС-68

Богданов В. С.

Проверил:

А. А. Крощенко

Ст. преп. кафедры ИИТ,

«___»_____ 2026 г.

Брест 2026

Цель работы: изучить применение линейной и логистической регрессии для решения практических задач. Научиться обучать модели, оценивать их качество с помощью соответствующих метрик и интерпретировать результаты.

Общее задание:

Выполнить задания по варианту (регрессия и классификация), построить все требуемые визуализации и рассчитать метрики, написать отчет, создать пул-реквест в репозиторий с кодом решения и отчетом в формате pdf.

Вариант 1

Регрессия (Прогнозирование стоимости жилья в Калифорнии)

- California Housing
- Предсказать медианную стоимость дома (median_house_value)
- **Задания:**
  - загрузите данные и разделите их на обучающую и тестовую выборки;
  - обучите модель **линейной регрессии** на обучающих данных;
  - сделайте предсказания для тестовой выборки;
  - оцените качество модели, рассчитав метрики **MSE** (Mean Squared Error) и **R^2** (Coefficient of Determination);
  - визуализируйте результат: постройте диаграмму рассеяния для признака median_income (медианный доход) и целевой переменной, нанеся на неё линию регрессии.

Классификация (Прогнозирование выживаемости на "Титанике")

- Titanic
- Предсказать, выжил ли пассажир (Survived)
- **Задания:**
  - загрузите и предварительно обработайте данные (заполните пропуски, преобразуйте категории в числа);
  - обучите модель **логистической регрессии**;
  - оцените качество модели, рассчитав **Accuracy**, **Precision** и **Recall**;
  - постройте и проанализируйте **матрицу ошибок** (confusion matrix).

Код программы:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression, LogisticRegression
from sklearn.metrics import (mean_squared_error, r2_score, accuracy_score,
                             precision_score, recall_score,
                             confusion_matrix, ConfusionMatrixDisplay)


# ============ РЕГРЕССИЯ: California Housing ============


# загрузка данных
df = pd.read_csv("california_housing.csv")


# (технически необходимая обработка: пропуски и текстовый признак)
df["total_bedrooms"] = df["total_bedrooms"].fillna(df["total_bedrooms"].median())
df = pd.get_dummies(df, columns=["ocean_proximity"], drop_first=True)


X = df.drop(columns="median_house_value")
y = df["median_house_value"]


# разделение на обучающую и тестовую выборки
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)


# обучение линейной регрессии
model = LinearRegression()
model.fit(X_train, y_train)


# предсказания для тестовой выборки
y_pred = model.predict(X_test)


# метрики MSE и R²
print("MSE =", mean_squared_error(y_test, y_pred))
print("R2  =", r2_score(y_test, y_pred))


# диаграмма рассеяния median_income / median_house_value с линией регрессии
line = LinearRegression().fit(X_train[["median_income"]], y_train)
xs = pd.DataFrame({"median_income": np.linspace(X["median_income"].min(),
                                                X["median_income"].max(), 100)})
plt.figure(figsize=(9, 6))
plt.scatter(X["median_income"], y, s=6, alpha=0.3)
plt.plot(xs["median_income"], line.predict(xs), color="red")
plt.xlabel("median_income")
plt.ylabel("median_house_value")
plt.title("California Housing: median_income vs median_house_value")
plt.show()


# ============ КЛАССИФИКАЦИЯ: Titanic ============


# загрузка и предварительная обработка
df = pd.read_csv("Titanic-Dataset.csv")
df = df.drop(columns=["PassengerId", "Name", "Ticket", "Cabin"])
df["Age"] = df["Age"].fillna(df["Age"].median())              # заполнение пропусков
df["Embarked"] = df["Embarked"].fillna(df["Embarked"].mode()[0])
df["Sex"] = df["Sex"].map({"male": 0, "female": 1})          # категории -> числа
df = pd.get_dummies(df, columns=["Embarked"], drop_first=True, dtype=int)


X = df.drop(columns="Survived")
y = df["Survived"]
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)


# обучение логистической регрессии
clf = LogisticRegression(max_iter=1000)
clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)


# Accuracy, Precision, Recall
print("Accuracy  =", accuracy_score(y_test, y_pred))
print("Precision =", precision_score(y_test, y_pred))
print("Recall    =", recall_score(y_test, y_pred))


# матрица ошибок
cm = confusion_matrix(y_test, y_pred)
print("Confusion matrix:\n", cm)
ConfusionMatrixDisplay(cm, display_labels=["Не выжил", "Выжил"]).plot(cmap="Blues")
plt.title("Titanic: матрица ошибок")
plt.show()
```

Результаты работы программы:

Регрессия (California Housing), метрики на тестовой выборке:

```
MSE = 4908476721.156605
R2  = 0.6254240620553615
```

Модель объясняет около 62,5% дисперсии стоимости жилья ($R^2 \approx 0{,}625$); среднеквадратичная ошибка составляет около 70 тыс. долларов ($RMSE = \sqrt{MSE} \approx 70\,060$).

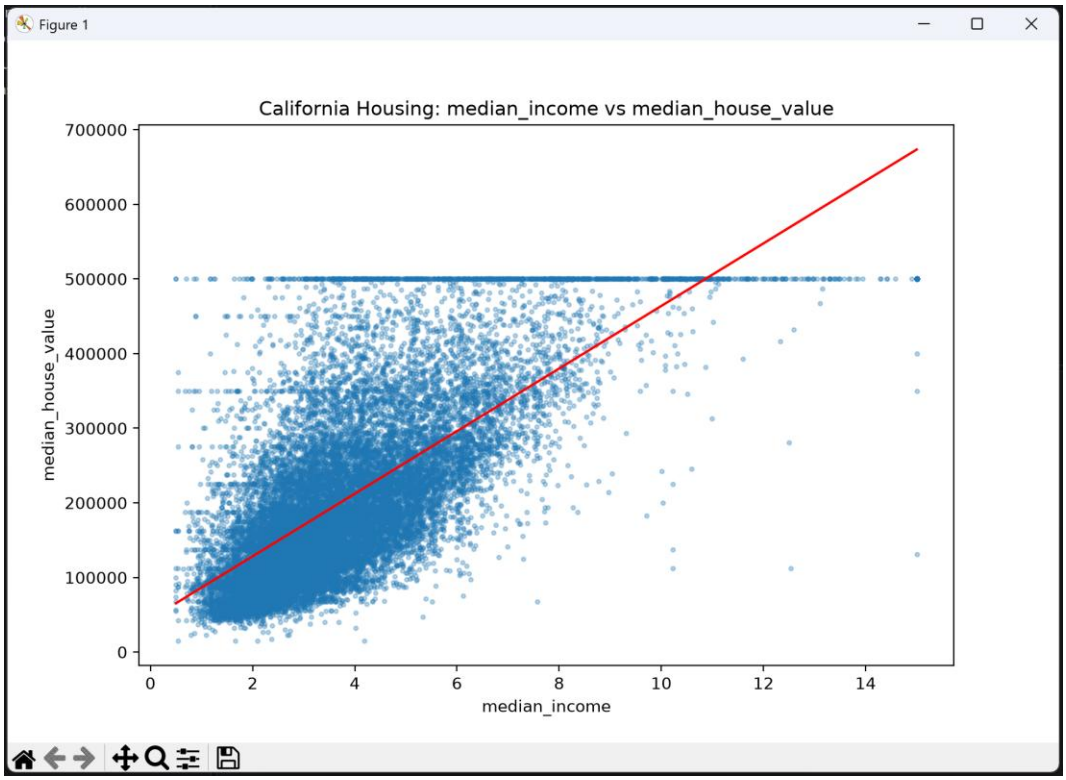


Рис. 1 – Диаграмма рассеяния median_income и median_house_value с линией регрессии (Python)

Положительный наклон линии показывает, что с ростом медианного дохода растёт и медианная стоимость дома. Горизонтальная полоса точек на уровне 500000 соответствует ограничению значений в данных сверху, из-за чего линейная модель хуже описывает дорогие районы.

Классификация (Titanic), метрики на тестовой выборке:

```
Accuracy  = 0.8100558659217877
Precision = 0.7857142857142857
Recall    = 0.7432432432432432
Confusion matrix:
 [[90 15]
 [19 55]]
```

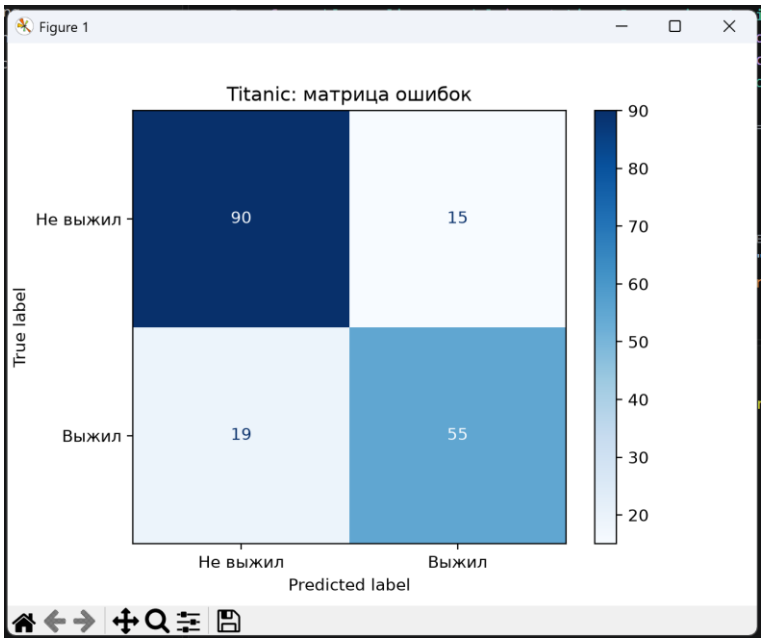
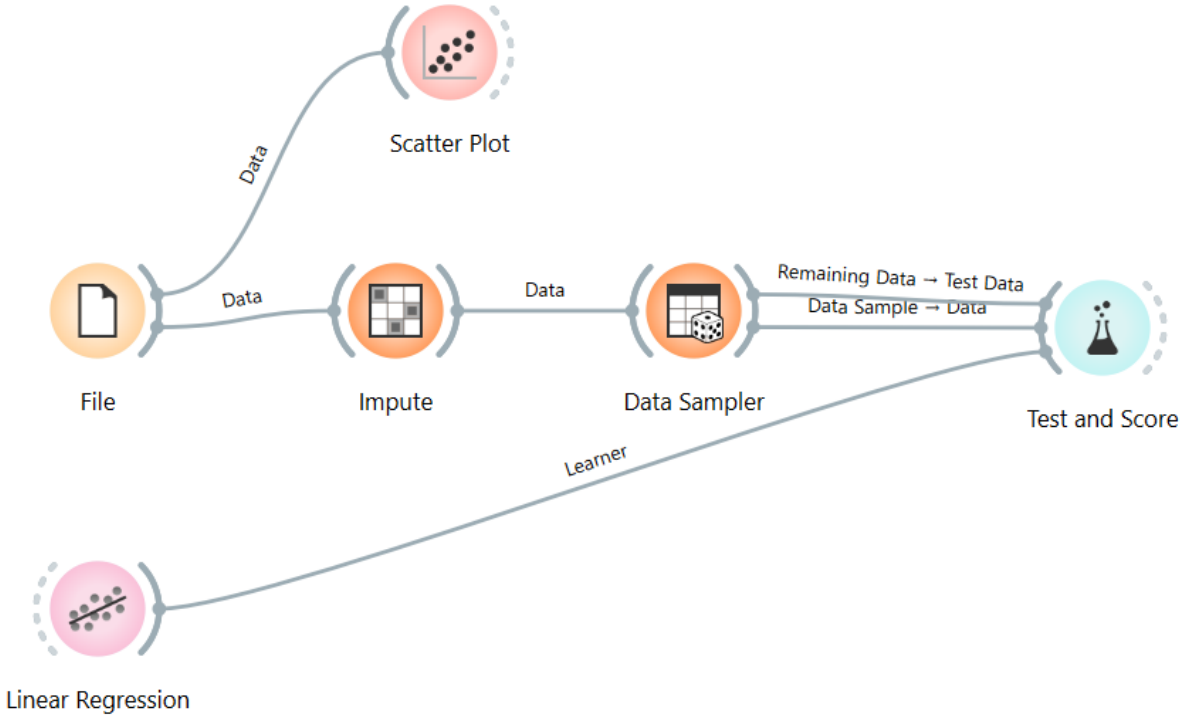


Рис. 2 – Матрица ошибок для модели логистической регрессии (Python)

Анализ матрицы ошибок. Из 179 пассажиров тестовой выборки модель верно определила 90 погибших (TN) и 55 выживших (TP). Ошибочно как выжившие предсказаны 15 пассажиров (FP), а 19 выживших модель приняла за погибших (FN). Accuracy = 0,810: правильно классифицировано около 81% пассажиров. Precision = 0,786: из пассажиров, которых модель назвала выжившими, 78,6% действительно выжили. Recall = 0,743: модель нашла около 74% всех действительно выживших. Ложноотрицательных срабатываний (19) больше, чем ложноположительных (15), поэтому Recall ниже Precision.

Orange:

Регрессия (Прогнозирование стоимости жилья в Калифорнии):



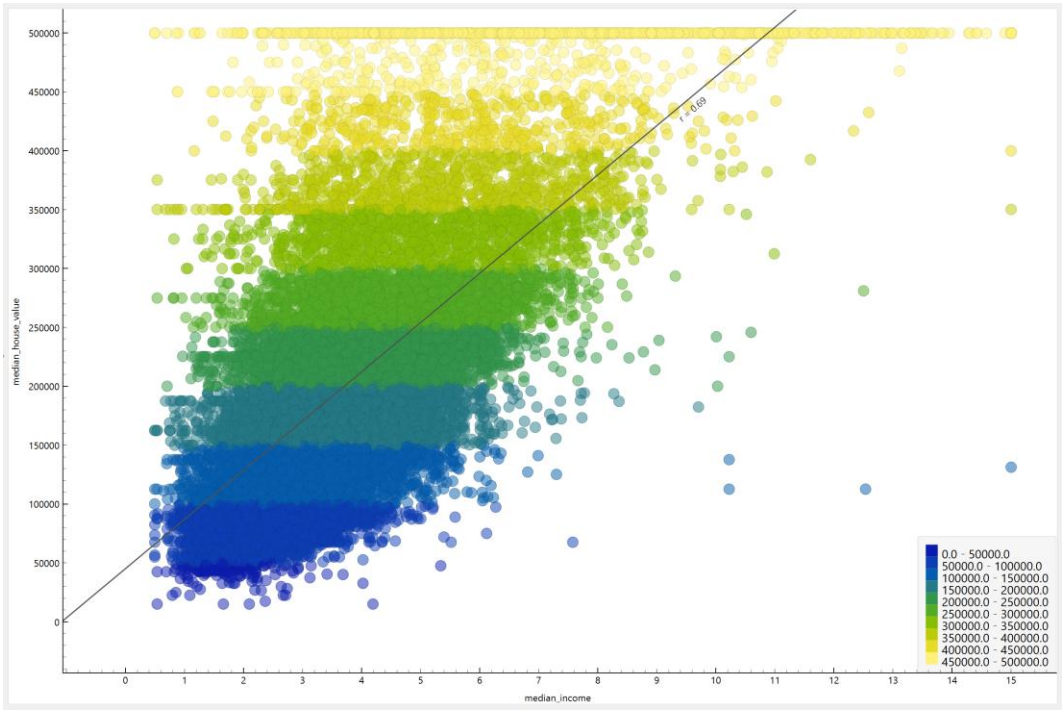


Рис. 3 – Scatter Plot в Orange: median_income и median_house_value с линией регрессии (r = 0,69)

Классификация (Прогнозирование выживаемости на "Титанике")

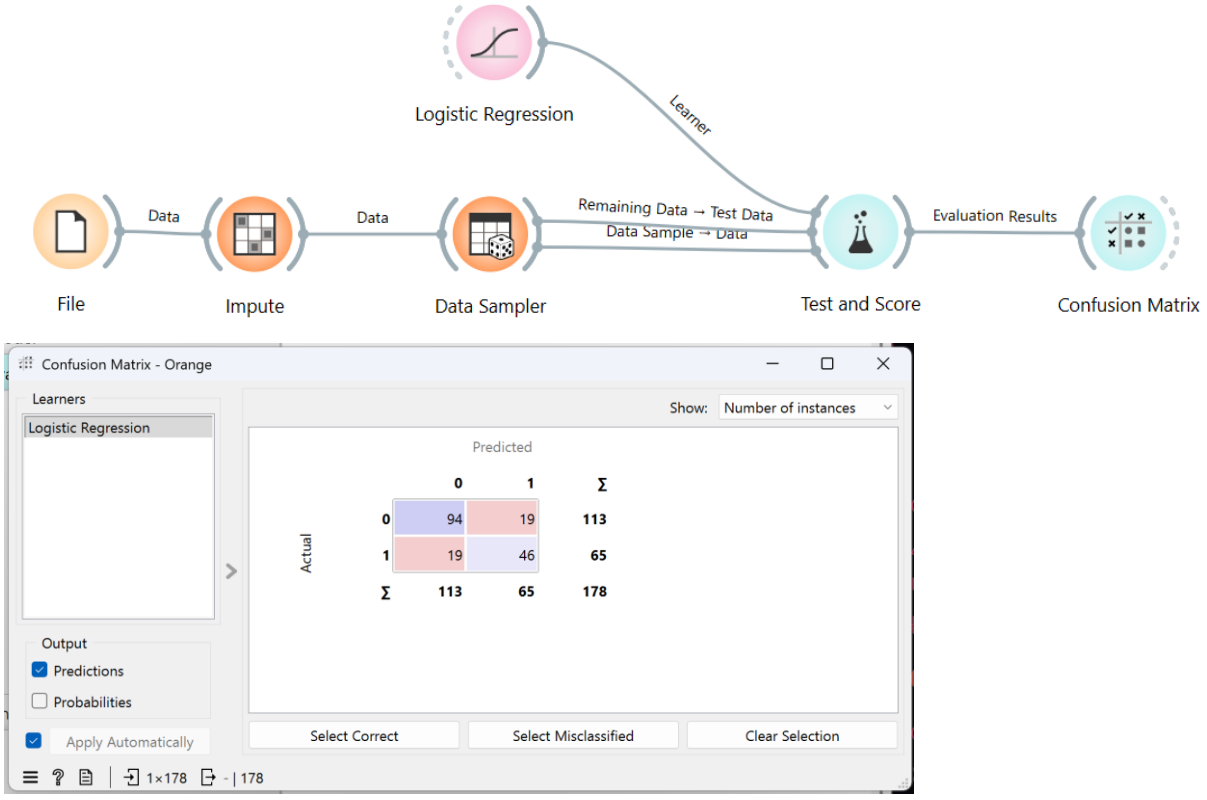


Рис. 4 – Confusion Matrix в Orange

По матрице ошибок Orange (178 объектов тестовой выборки): TN = 94, FP = 19, FN = 19, TP = 46. Отсюда Accuracy = (94 + 46) / 178 ≈ 0,787, Precision = 46 / 65 ≈ 0,708, Recall = 46 / 65 ≈ 0,708. Значения немного отличаются от результатов Python, так как в Orange используется другое разбиение данных на выборки и другие настройки регуляризации логистической регрессии.

Вывод: изучил применение линейной и логистической регрессии для решения практических задач. Научился обучать модели, оценивать их качество с помощью соответствующих метрик и интерпретировать результаты. Линейная регрессия на данных California Housing показала $R^2 = 0,625$, логистическая регрессия на данных Titanic – Accuracy = 0,810.