Министерство образования Республики Беларусь
Учреждение образования
«Брестский Государственный технический университет»
Кафедра ИИТ

Лабораторная работа №3
По дисциплине «ОМО»

Выполнил:
Студент 3-го курса
Группы АС-68
Жуков А.А.
Проверил:
Крощенко А.А.

Брест 2026

Цель работы: На практике сравнить работу нескольких алгоритмов классификации, таких как **метод k-ближайших соседей(k-NN), деревья решений** и **метод опорных векторов (SVM).** Научится подбирать гиперпараметры моделей и оценивать их влияния на результат.

Ход работы

Задачи:

1. Загрузить датасет по варианту;
2. Разделить данные на обучающую и тестовую выборки;
3. Обучить на обучающей выборке три модели: k-NN, Decision Tree и SVM;
4. Для модели k-NN исследовать, как меняется качество при разном количестве соседей (k);
5. Оценить точность каждой модели на тестовой выборке;
6. Сравнить результаты, сделать выводы о применимости каждого метода для данного набора данных.

Вариант 2

- *Breast Cancer Wisconsin*
- Определить, является ли опухоль злокачественной (malignant) или доброкачественной (benign);
- Задания:
  1. Загрузите данные и выполните стандартизацию признаков;
  2. Разделите данные на обучающую и тестовую части;
  3. Обучите три классификатора: k-NN, Decision Tree и SVM;
  4. Для каждой модели постройте матрицу ошибок и рассчитайте метрики precision, recall и F1-score для класса "злокачественная опухоль";
  5. Сравните модели и укажите, какая из них наиболее надежна для минимизации ложноотрицательных прогнозов (когда злокачественная опухоль определяется как доброкачественная).

Код программы для первого задания lab3.py:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.svm import SVC
from sklearn.metrics import confusion_matrix, precision_score,
recall_score, f1_score

df = pd.read_csv("breast_cancer.csv")
```

```
if 'id' in df.columns:
    df = df.drop(columns=['id'])
if 'Unnamed: 32' in df.columns:
    df = df.drop(columns=['Unnamed: 32'])

y = df['diagnosis'].map({'M':1, 'B':0})

X = df.drop(columns=['diagnosis'])

X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.2, random_state=42, stratify=y)

scaler = StandardScaler()
X_train_scaler = scaler.fit_transform(X_train)
X_test_scaler = scaler.transform(X_test)

knn = KNeighborsClassifier(n_neighbors=5)
tree = DecisionTreeClassifier(max_depth=4, random_state=42)
svm = SVC(kernel='rbf', C=1.0, random_state=42)

models = {
    "k-NN" : knn,
    "Desicion Tree" : tree,
    "SVM" : svm
}

result = []
fig, axes = plt.subplots(1,3, figsize=(18, 5))

for i, (name, model) in enumerate(models.items()):
    model.fit(X_train_scaler, y_train)
    y_pred = model.predict(X_test_scaler)

    prec = precision_score(y_test, y_pred)
    rec = recall_score(y_test, y_pred)
    f1 = f1_score(y_test, y_pred)

    result.append({
        "Модель" : name,
        "Precision" : prec,
        "Recall" : rec,
        "F1-score" : f1
    })

    cm = confusion_matrix(y_test, y_pred)
    sns.heatmap(cm, annot=True, fmt="d", cmap="Blues", ax=axes[i],
                xticklabels=["Доброкач. (0)", "Злокач. (1)"],
                yticklabels=["Доброкач. (0)", "Злокач. (1)"])
    axes[i].set_title(f"{name}\nRecall: {rec:.3f}")
    axes[i].set_xlabel("Предсказано")
    axes[i].set_ylabel("Истинно")

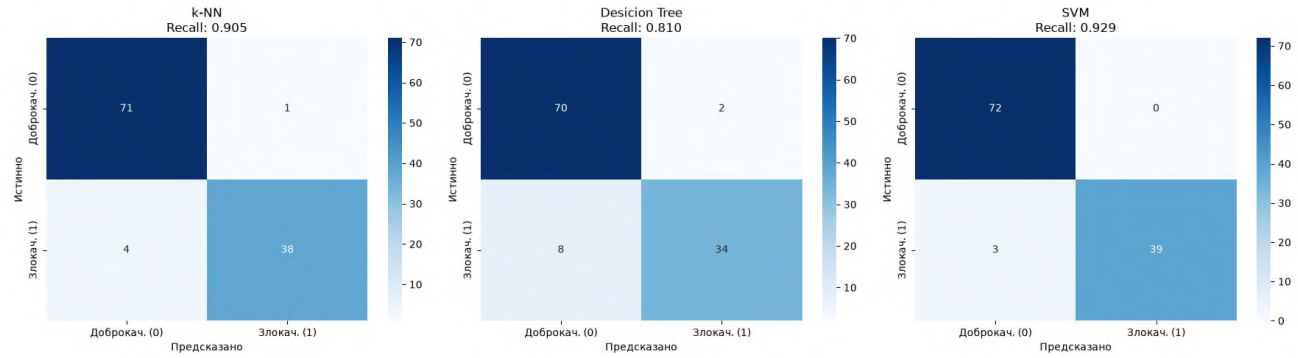
plt.tight_layout()
plt.show()

df_result = pd.DataFrame(result).sort_values(by="Recall",
ascending=False)
print("Сравнение моделей")
```

```
print(df_result.to_string(index=False))

best_model = df_result.iloc[0]["Модель"]
print(f"\nНаиболее надежная модель для минимизации ложноотрицательных прогнозов: {best_model}")
```

Вывод результата




```
Сравнение моделей
        Модель  Precision   Recall  F1-score
           SVM   1.000000 0.928571  0.962963
          k-NN   0.974359 0.904762  0.938272
Desicion Tree   0.944444 0.809524  0.871795

Наиболее надежная модель для минимизации ложноотрицательных прогнозов: SVM
```

Анализ метрик на тестовой выборке показал следующие результаты:

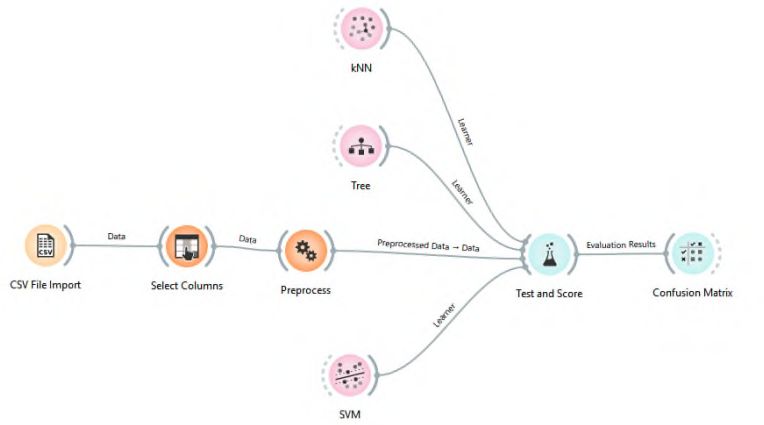
SVM показал наилучшие результаты: **Precision = 1.0**, **Recall = 0.928**, **F1-score = 0.962**.

k-NN занял второе место: Precision = 0.974, Recall = 0.904, F1-score = 0.938.

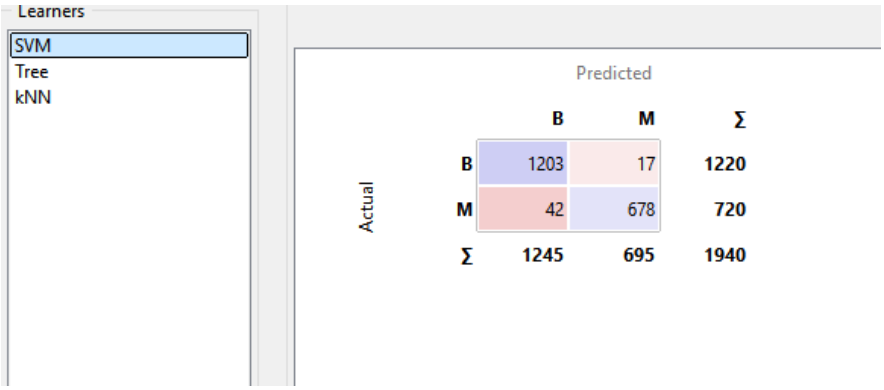
Decision Tree показал худшие результаты: Precision = 0.944, **Recall = 0.809**, F1-score = 0.871.

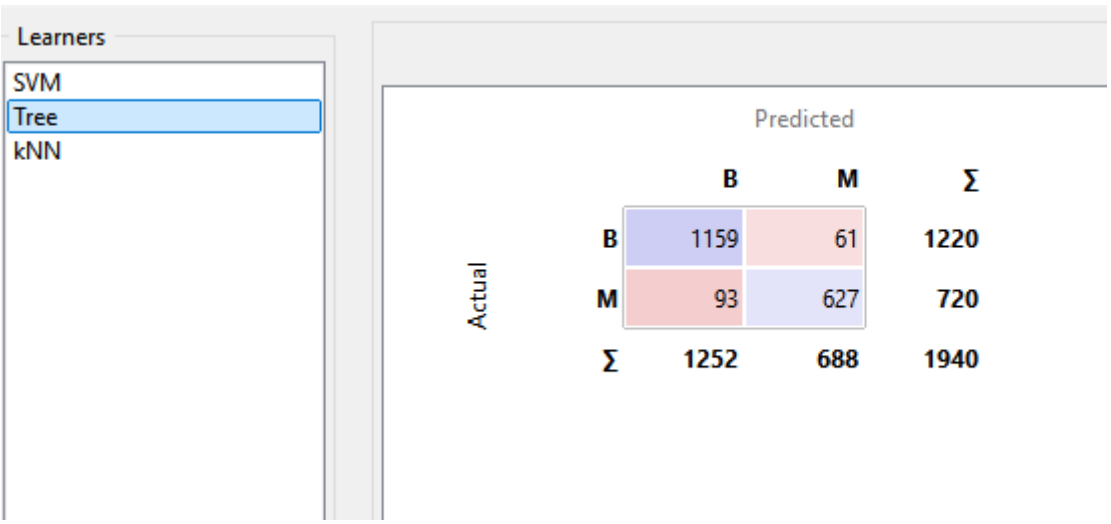
Наиболее надежной моделью для минимизации ложноотрицательных прогнозов (FN — когда злокачественная опухоль ошибочно признается доброкачественной) является **SVM**. Это подтверждается наивысшим значением метрики **Recall (0.928)**. Это означает, что модель смогла найти 92,8% всех реально больных пациентов, пропустив минимальное количество случаев.

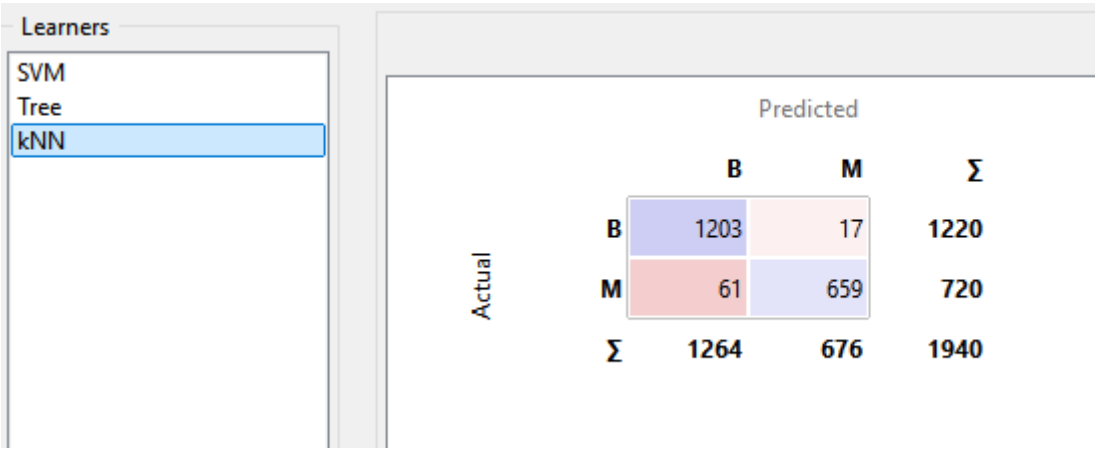
Результаты в Orange:



Model	AUC	CA	F1	Prec	Recall	MCC
SVM	0.994	0.970	0.958	0.976	0.942	0.935
Tree	0.917	0.921	0.891	0.911	0.871	0.829
kNN	0.984	0.960	0.944	0.975	0.915	0.914







Вывод: на практике сравнил работу алгоритмов классификации, таких как метод k-ближайших соседей (k-NN), деревья решений и метод опорных векторов (SVM). Научился подбирать гиперпараметры моделей и оценивать их влияние на результат